


汇报PPT的主要内容

面向智能客服的AI Agent 血糖管理自进化系统


成员：A B C

时间：2026年3月27日


项目组成员及分工问题C



姓名：XXX(组长)
专业：
个人简介：
分工：




姓名：
专业：
个人简介：
分工：




姓名：
专业：
个人简介：
分工：

项目名称：面向智能客服的AI Agent 血糖管理自进化系统

项目简介




Architecture Layers



项目整体框架

记忆管理Agent的架构



短期记忆	当前对话历史 + 本轮各专家 Agent 的推理输出 实时更新，对话结束后部分转入中期记忆
中期记忆	近期血糖趋势 (7天/30天统计) · 用药调整 (换药、加量) · 饮食运动记录
长期记忆	患者画像: 基本信息、病史、过敏史、用药史 重要事件: 住院、严重低血糖、换药节点、并发症

三层记忆的定义

层次	特征	生命周期	在 Memory Palace 中的对应
短期记忆	高新鲜度、碎片化、易遗忘	会话级或数小时	新写入的记忆，活力值初始高；尚未被整合
中期记忆	经过筛选、被多次检索或更新	数天 ~ 数周	活力值中等，可能已被整合为摘要 (gist)
长期记忆	核心知识、高度稳固、可检索	持久保存，仅手动删除	高活力、或已被合并为“长期摘要”节点，且通过审查保留快照

示例流程

- AI 写入 5 条短期记忆，如“患者血糖 8.2”、“饮食记录 2025-03-23”等。
- 系统检测到短期记忆过多，自动触发整合，生成一条中期摘要“近一周血糖与饮食概况”，并将原短期记忆标记为“已整合”。
- 主治医生在仪表盘中看到该中期摘要，认为很有价值，点击“提升为长期记忆”。
- 系统将这条摘要的 `memory_layer` 改为 `long`，并锁定活力值（不再衰减）。
- 半年后，其他 AI 检索“血糖历史”时，系统优先返回这条长期摘要，避免了大量短期细节的干扰。

Agent 角色		
专家	定位	权限与职责
主治医生	组长	全局负责人，可添加/启动/停止任何 Actor，接收 idle 和 quiet-review 通知，可对任何任务做出最终决策。
药剂师	专家	负责用药方案，可质疑主治医生的处方，但只能管理与自己相关的任务（如药物审核）。
营养师	专家	制定饮食计划，可对代谢相关问题提出建议，但无权修改其他领域的方案。
代谢病医生	专家	专注于胰岛素抵抗、血糖波动等代谢异常，可挑战主治医生的代谢相关决策。
科普老师	专家	生成患者教育内容，可被@要求制作科普材料，但不能干预临床治疗。
心理咨询师	专家	关注患者心理状态，可发起心理干预或转诊建议，但不能修改药物/饮食方案。
记忆管理	记忆模块	所有Agent记忆的储存管理

权限与职权解释

- 组长唯一：确保治疗决策有明确最终责任人。
- 专家可质疑组长：体现多学科协作中的制衡机制，提高决策质量。
- 专家只能管理自己：避免权限混乱，保障系统安全。

应用场景		
 自动化规则（让系统主动推进）		
利用 自动化引擎，可以设置多种规则，减少人工盯梢：		
规则类型	触发条件	执行动作
每日摘要	每天 8:00	发送 @主治医生 “昨日血糖数据汇总，请查收”
药物审核催办	药剂师被@后 4 小时未回复	向主治医生发送升级提醒
饮食方案确认	营养师提交方案后 24 小时未获主治医生确认	自动@主治医生 “待确认饮食方案”
定期科普推送	每周三 10:00	发送 @科普老师 “本周主题：低血糖识别与应对”
心理干预触发	患者连续 3 天情绪相关记录异常	自动@心理咨询师 “请评估患者心理状态”
代谢异常告警	连续血糖值超过阈值	发送 @代谢病医生 “需调整胰岛素剂量” 并同时抄送主治医生
这些规则既可以通过 Web UI 的可视化编辑器配置，也可以通过 CLI 或 API 定义。		

Permission Matrix

Action	user	foreman	peer	peer
actor_add	✓	✓	X	X
actor_start	✓	✓ (any)	X	X
actor_stop	✓	✓ (any)	✓ (self)	✓ (self)
actor_restart	✓	✓ (any)	✓ (self)	✓ (self)
actor_remove	✓	✓ (self)	✓ (self)	✓ (self)

系统可以实现**智能体克隆**以及**智能体的自动增减**

项目创新点

Agent自进化（提示词+memory）

三层记忆管理

项目进度

自进化系统整体框架的初步搭建

多Agent架构及代码实现

三层记忆架构设计及初步配置

三层记忆架构的具体建议

要在 Memory Palace 中实现短期、中期、长期三层记忆架构，核心是利用**活力值（vitality）衰减**、**睡眠整合（consolidation）**和**快照归档**来模拟记忆从“新鲜”到“沉淀”的生命周期。下面给出具体的设计思路 and 实现方式。

🧠 三层记忆的定义

层次	特征	生命周期	在 Memory Palace 中的对应
短期记忆	高新鲜度、碎片化、易遗忘	会话级或数小时	新写入的记忆，活力值初始高；尚未被整合
中期记忆	经过筛选、被多次检索或更新	数天 ~ 数周	活力值中等，可能已被整合为摘要（gist）
长期记忆	核心知识、高度稳固、可检索	持久保存，仅手动删除	高活力、或已被合并为“长期摘要”节点，且通过审查保留快照

1 短期记忆的实现

- **写入时默认标记为短期**：所有通过 `create_memory` 写入的新节点，活力值设为最大值（例如 3.0），并打上 `fresh: true` 标记（可存在元数据）。
- **存储位置**：短期记忆与中期、长期记忆共用同一 SQLite 数据库，但通过 **活力值** 和 **时间戳** 区分。
- **检索策略**：在档位 B/C/D 中，可以对短期记忆增加时效性加权（例如 `RECENCY_WEIGHT`），让最近写入的内容在搜索结果中更靠前。
- **自动整合**：系统定期（如每小时）检查是否存在碎片化短期记忆，当某个域下的短期记忆条目超过阈值（如 10 条）时，自动触发 `compact_context` 或 `rebuild_index`，将它们整合成一条或多条中期摘要（gist）。整合后原短期记忆可标记为“已整合”或直接删除。

2 中期记忆的实现

- **整合后的摘要节点**：由短期记忆整合生成的 gist 节点，其活力值继承自被整合节点的平均活力（或设为中等初始值），并添加 `consolidated: true` 标签。
- **保留原始痕迹**：在快照（review session）中保留整合前的原始短期记忆快照，以便审计或回滚。
- **进一步衰减与再整合**：中期记忆若长期未被访问，活力值继续衰减。当活力值低于阈值（如 0.5）且存在多个相似中期记忆时，可再次整合为更高级的长期摘要。

3 长期记忆的实现

- **人工或自动标记**：对于核心知识，可以通过仪表盘的“审查”功能，将某条记忆手动提升为长期记忆（例如设置 `permanent: true`，或锁定活力值不再衰减）。
- **自动晋升**：若某条中期记忆在多次检索中都被命中，且活力值稳定在较高水平，系统可自动将其标记为长期记忆（例如 `vitality >= 2.5` 持续 30 天）。
- **存储优化**：长期记忆可以单独建立**摘要索引**，将多个相关长期记忆进一步融合成“知识主题”，避免检索时返回过多冗余信息。
- **快照保留**：长期记忆的每一次修改都会通过快照机制保留，形成不可篡改的演进历史。



🔧 在 Memory Palace 中的具体配置

活力值衰减参数

在 `.env` 中调整：

```
bash
```



复制



下载

```
VITALITY_DECAY_HALF_LIFE_DAYS=30      # 活力值半衰期
VITALITY_CLEANUP_THRESHOLD=0.35       # 低于此值可清理
VITALITY_CLEANUP_INACTIVE_DAYS=14     # 无访问超过此天数可清理
```

将短期记忆的初始活力设为 3.0，中期设为 1.5 ~ 2.0，长期可设为 3.0 且衰减禁用。

整合策略（在 `runtime_state.py` 中可定制）

- 设置 `COMPACT_CONTEXT_TRIGGER_SIZE`：当某个域内短期记忆超过该数量时自动整合。
- 使用 `rebuild_index(consolidate=True, domain=...)` 手动整合特定域。



检索时的时效性加权

在 `sqlite_client.py` 中修改检索评分公式，例如：

python

 复制  下载

```
score = keyword_score * keyword_weight + semantic_score * semantic_weight + recency_bonus
```

其中 `recency_bonus = 1 / (1 + (now - updated_at).days * decay_factor)`。

仪表盘增强

- 在记忆浏览器中，用不同图标或颜色区分短期、中期、长期记忆。
- 在维护页面，增加“手动晋升为长期记忆”按钮，允许用户锁定某条记忆。
- 在可观测性页面，展示各层记忆的数量和活力分布。



三层记忆的数据模型（扩展）

在现有 `nodes` 表基础上增加字段：

sql

 复制  下载

```
ALTER TABLE nodes ADD COLUMN memory_layer TEXT DEFAULT 'short'; -- short, medium, long
ALTER TABLE nodes ADD COLUMN consolidated_from TEXT;           -- 记录由哪些短期节点整合而来
ALTER TABLE nodes ADD COLUMN permanent BOOLEAN DEFAULT FALSE;  -- 长期记忆锁定标志
```

整合时创建新的 gist 节点，其 `memory_layer` 设为 `medium`，`consolidated_from` 存储原始节点 URI 列表。

示例流程

1. AI 写入 5 条短期记忆，如“患者血糖 8.2”、“饮食记录 2025-03-23”等。
2. 系统检测到短期记忆过多，自动触发整合，生成一条中期摘要“近一周血糖与饮食概况”，并将原短期记忆标记为“已整合”。
3. 主治医生在仪表盘中看到该中期摘要，认为很有价值，点击“提升为长期记忆”。
4. 系统将这条摘要的 `memory_layer` 改为 `long`，并锁定活力值（不再衰减）。
5. 半年后，其他 AI 检索“血糖历史”时，系统优先返回这条长期摘要，避免了大量短期细节的干扰。

总结

Memory Palace 通过**活力值衰减 + 自动整合 + 用户干预**，完全可以模拟出短期、中期、长期三层记忆架构。短期记忆新鲜但易整合，中期记忆是提炼后的知识块，长期记忆是稳固的核心知识。这种设计既保证了记忆库的“新陈代谢”，又让重要信息得以永久保留，非常适合需要持续学习的 AI 应用场景。

